Университет ИТМО
Дисциплина «Инженерия данных»

Домашнее задание № 3

Объектное хранилище RustFS, собственный MapReduce и DuckDB: навыки, зарплаты и регионы в вакансиях hh.ru

Вариант 10 — Аналитики

Выполнила: Голубева Мария Сергеевна
Группа J3313, ИСУ 465572

Репозиторий: `https://github.com/masha363/data-engineering-hw3`

Санкт-Петербург, 2026

Содержание и окружение

1. Развёртывание RustFS
2. Подготовка и загрузка данных в бакет `hh-lake`
3. Подсчёт навыков, пар и троек: собственный MapReduce и DuckDB
4. Верификация
5. Влияние навыков на зарплату
6. Региональный анализ
7. Профилирование и оптимизация (бонус)
8. Выводы

Машина	MacBook Air (Apple Silicon), 8 ядер, 8 ГБ RAM, macOS
Хранилище	RustFS v1.0.3 в Docker, 4 диска (`disks/disk0..3`), Erasure Coding `EC:2`, S3 API на `localhost:9000`
ПО	Python 3.14, boto3 1.43.116, DuckDB 1.5.6 (расширение httpfs), psutil, matplotlib
Данные	выгрузка вакансий hh.ru за 2024 г. `vacancies_2024.csv` (25 ГБ, ~9,5 млн строк)
Код	`common.py`, `00_prepare.py`, `01_upload.py`, `mapreduce.py`, `mapreduce_v2.py`, `duckdb_skills.py`, `verify.py`, `salary.py`, `regions.py`, `profile_runs.py`, `make_charts.py`

Условие варианта. Вакансии сегмента «аналитики» — это вакансии с IT-профролью hh.ru (поле `role`) из списка: «Аналитик», «Системный аналитик», «Бизнес-аналитик», «BI-аналитик, аналитик данных», «Продуктовый аналитик». Финансовые аналитики, маркетологи-аналитики и руководители отделов аналитики не относятся к IT-сегменту и в вариант не входят. Условие задано в `common.py` (`VARIANT_ROLES` / `VARIANT_SQL`) и применяется независимо в MapReduce (Python) и в DuckDB (SQL `WHERE role IN (...)`).

Нормализация навыков (одинаковая в обоих способах): строка `key_skills` делится по «;», у каждого навыка обрезаются пробелы, пустые отбрасываются, дубликаты внутри вакансии убираются. Сочетания строятся из отсортированного множества навыков, поэтому пара (A,B) и (B,A) — одно сочетание.

1. Развёртывание объектного хранилища RustFS

Я использовала стенд из ДЗ 2 (`docker-compose.yml`): один узел RustFS с четырьмя дисками-каталогами и стандартным классом хранения EC:2 (2 блока данных + 2 блока чётности, переживает потерю любых двух дисков). Запуск — `docker compose up -d`.

Файл `docker-compose.yml`

```
services:
  rustfs:
    image: rustfs/rustfs:latest
    container_name: rustfs
    ports:
      - "9000:9000"
      - "9001:9001"
    environment:
      RUSTFS_VOLUMES: "/data/rustfs{0...3}"
      RUSTFS_STORAGE_CLASS_STANDARD: "EC:2"
      RUSTFS_HEAL_AUTO_HEAL_ENABLE: "false"
      RUSTFS_UNSAFE_BYPASS_DISK_CHECK: "true"
      RUSTFS_ACCESS_KEY: "rustfsadmin"
      RUSTFS_SECRET_KEY: "rustfsadmin"
    volumes:
      - ./disks/disk0:/data/rustfs0
      - ./disks/disk1:/data/rustfs1
      - ./disks/disk2:/data/rustfs2
      - ./disks/disk3:/data/rustfs3
```

```
golubevamaria@MacBook-Air-Golubeva rustfs-lab % docker ps
CONTAINER ID   IMAGE                                                COMMAND                  CREATED
          STATUS          PORTS                                                                  NAMES
177e9cb9d55d   rustfs/rustfs:latest                                 "/entrypoint.sh rust…"   12 seco
nds ago   Up 11 seconds   0.0.0.0:9000-9001->9000-9001/tcp, [::]:9000-9001->9000-9001/tcp        rustfs
4cd9c1da2acc   nature-se-go-2026-c122-grpc-a136-masha363-frontend   "/docker-entrypoint.…"   12 hour
s ago     Up 12 hours     0.0.0.0:5173->80/tcp, [::]:5173->80/tcp                                nature-s
e-go-2026-c122-grpc-a136-masha363-frontend-1
3938812b4f5f   nature-se-go-2026-c122-grpc-a136-masha363-gateway    "/app/gateway"           12 hour
s ago     Up 12 hours     0.0.0.0:8080->8080/tcp, [::]:8080->8080/tcp                            nature-s
e-go-2026-c122-grpc-a136-masha363-gateway-1
29d126452806   nature-se-go-2026-c122-grpc-a136-masha363-cart       "./cart"                 12 hour
s ago     Up 12 hours     0.0.0.0:50051->50051/tcp, [::]:50051->50051/tcp                        nature-s
e-go-2026-c122-grpc-a136-masha363-cart-1
18b324ed157d   nature-se-go-2026-c122-grpc-a136-masha363-loms       "./loms"                 12 hour
s ago     Up 12 hours     0.0.0.0:50052->50052/tcp, [::]:50052->50052/tcp                        nature-s
e-go-2026-c122-grpc-a136-masha363-loms-1
dfd50b8b72d2   nature-se-go-2026-c122-grpc-a136-masha363-notifier   "/app/notifier"          12 hour
s ago     Up 12 hours                                                                            nature-s
e-go-2026-c122-grpc-a136-masha363-notifier-1
e61ea233e4b6   nature-se-go-2026-c122-grpc-a136-masha363-billing    "java -XX:MaxRAMPerc…"   12 hour
s ago     Up 12 hours     0.0.0.0:50054->50054/tcp, [::]:50054->50054/tcp                        nature-s
e-go-2026-c122-grpc-a136-masha363-billing-1
f180c360bffd   nature-se-go-2026-c122-grpc-a136-masha363-telegram   "python -u /app/tele…"   12 hour
s ago     Up 12 hours     0.0.0.0:8094->8080/tcp, [::]:8094->8080/tcp                            nature-s
e-go-2026-c122-grpc-a136-masha363-telegram-1
golubevamaria@MacBook-Air-Golubeva rustfs-lab %
```

Рис. 1. Контейнер rustfs запущен (docker ps)

2. Подготовка и загрузка данных

Полная выгрузка весит 25 ГБ, а на диске ноутбука свободно ~17 ГБ; при EC:2 объект занимает на дисках в 2 раза больше, поэтому целиком файл в хранилище не помещается. Поэтому я написала скрипт `00_prepare.py`, который локальным DuckDB вырезает из выгрузки все вакансии с профролью, содержащей «аналит» (это шире варианта: сюда попадают и финансовые, и маркетинговые аналитики), и убирает дубли снимков по `vacancy_id` (остаётся последний снимок). Точное условие варианта применяется уже на этапе 3 — каждым из двух способов самостоятельно.

Вывод: `logs/02_prepare.txt`

```
(.venv) golubevamaria@MacBook-Air-Golubeva hw3 % python 00_prepare.py
Вакансий с ролью *аналит* (без дублей): 73522
[('Аналитик', 30112), ('Финансовый аналитик, инвестиционный аналитик', 12113), ('Системный аналитик', 10609),
('Бизнес-аналитик', 8232), ('Маркетолог-аналитик', 5365), ('BI-аналитик, аналитик данных', 3969), ('Продуктовый
аналитик', 1685), ('Руководитель отдела аналитики', 1437)]
Записано в ../data/hh_analysts_2024.csv за 20.5 с
```

`01_upload.py` создаёт бакет `hh-lake` и кладёт срез объектом `raw/hh_analysts_2024.csv` (284 МБ), затем сверяет размер объекта в S3 с локальным файлом.

Вывод: `logs/02_upload.txt`

```
(.venv) golubevamaria@MacBook-Air-Golubeva hw3 % python 01_upload.py
Endpoint: http://localhost:9000
Создан бакет hh-lake
Загружено s3://hh-lake/raw/hh_analysts_2024.csv
  локальный размер : 284287850 байт, md5 60de9ae1bf0458b1d381aa7588030195
  размер в S3      : 284287850 байт

Содержимое бакета:
  raw/hh_analysts_2024.csv                          284287850 байт  2026-10-21 08:09:43
```

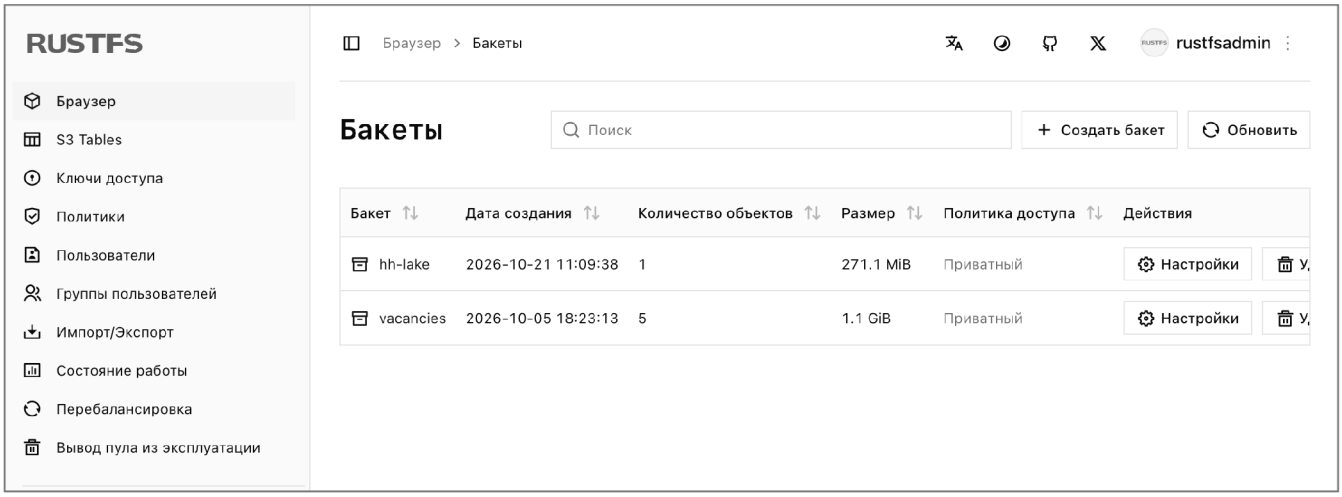


Рис. 2. Бакет hh-lake в консоли RustFS

Найденная особенность стенда. При сохранении результатов у меня RustFS отвечал `InternalError` (HTTP 500) на обычный `PutObject`. Я провела диагностику (`s3_test.py`, `s3_test2.py`), и она показала, что это зависит только от размера объекта: 100 и 200 КБ записываются, 400 КБ и больше — нет, независимо от содержимого (ASCII, случайные байты, CSV) и клиента (boto3 и `aws s3 cp` падали одинаково). Объекты до ~256 КБ RustFS хранит inline в метаданных `xl.meta`, а крупные пишет блоками EC на диски — на этом пути одиночный PUT и ломался. Multipart upload при этом работает (именно им загружен исходный объект на 284 МБ). Поэтому все записи в бакет я сделала через multipart (`put_bytes` в `common.py`), в том числе результаты DuckDB: он сохраняет CSV локально, а в бакет файл уходит multipart-загрузкой. Тем же сбоем объясняется тестовый объект `results/mapreduce/x.txt` (5 байт), видный в выводах `verify.py`: это след диагностики, а удалить его не удалось — `DeleteObject` на этом стенде тоже отвечает `InternalError`. На результаты он не влияет: сверка читает только файлы `k1/k2/k3` и `summary.json`.

3. Подсчёт навыков, пар и троек

3.1. Собственный MapReduce (`mapreduce.py`)

- **Чтение чанками из S3.** Драйвер узнаёт размер объекта (`HEAD`) и читает его HTTP-запросами `GET` с заголовком `Range: bytes=pos-end` по 8 МБ. Описания вакансий многострочные, поэтому резать по любому `\n` нельзя: разрез делается по последнему переводу строки, перед которым в буфере *чётное* число кавычек, т.е. который не лежит внутри поля в кавычках. Хвост переносится в следующий чанк. Так каждый чанк содержит только целые записи CSV.
- **Map.** Чанки отдаются пулу процессов (`ProcessPoolExecutor`, 4 воркера). Маппер парсит CSV, применяет условие варианта, нормализует навыки и считает сочетания `itertools.combinations(skills, k)` для k = 1, 2, 3. Внутри маппера работает **combiner**: одинаковые ключи сразу суммируются в `Counter`, наружу уходит свёртка чанка, а не поток пар (ключ, 1).
- **Shuffle.** Каждый ключ отправляется в одну из R = 4 партиций по `crc32(ключ) mod R` (стабильный хеш, в отличие от встроенного `hash()`).
- **Reduce.** Редьюсер партиции суммирует счётчики; партиции не пересекаются по ключам, поэтому итог — их объединение.
- **Отказоустойчивость.** Если маппер падает, драйвер ловит исключение и перезапускает тот же чанк (данные чанка у него остались). Отказ имитируется ключом `--fail-chunk N`.
- **Ограничение памяти.** В работе одновременно не больше 2×(число воркеров) чанков — драйвер не вычитывает весь объект вперёд.

- **Результат** для трёх размеров стека k = 1, 2, 3 сохраняется в бакет: `results/mapreduce/k1_skills.csv`, `k2_pairs.csv`, `k3_triples.csv` и `summary.json` с контрольными числами.

Вывод: `logs/03_mapreduce.txt`

```
=== MAPREDUCE | вариант: аналитики ===
строк в объекте: 73522, вакансий варианта: 54607, с навыками: 33662
k=1 навыки  уникальных:      9219   всего вхождений:     231229
k=2 пары    уникальных:    157717   всего вхождений:    1004033
k=3 тройки  уникальных:   1116083   всего вхождений:    3872336
проверка: Σ C(n,2) = 1004033, Σ C(n,3) = 3872336

Топ-10 навыков:
   10653  SQL
    8157  Аналитическое мышление
    6464  BPMN
    5894  Бизнес-анализ
    5226  Системный анализ
    5062  Анализ данных
    4767  UML
    4452  Разработка технических заданий
    4305  Работа с большим объемом информации
    3877  MS Excel

Топ-10 пар:
    3880  BPMN + UML
    2966  BPMN + SQL
    2681  SQL + UML
    2671  Python + SQL
    2507  Анализ данных + Аналитическое мышление
    2442  SQL + Системный анализ
    2238  BPMN + Системный анализ
    2236  Аналитическое мышление + Работа с большим объемом информации
    2055  UML + Системный анализ
    2050  SQL + Аналитическое мышление

Топ-10 троек:
    2201  BPMN + SQL + UML
    1699  BPMN + UML + Системный анализ
    1387  BPMN + REST + UML
    1266  BPMN + SQL + Системный анализ
    1236  SQL + UML + Системный анализ
    1213  REST + SQL + UML
    1186  BPMN + REST + SQL
    1012  REST + SOAP + SQL
    1002  Анализ данных + Аналитическое мышление + Работа с большим объемом информации
     933  BPMN + UML + Бизнес-анализ

 {'chunk_mb': 8, 'workers': 4, 'chunks': 34, 'retries': 0, 'seconds': 6.57}
```

3.2. Тест с отказом маппера

Маппер на чанке 5 при первой попытке выбрасывает исключение; драйвер перезапускает чанк (`retries: 1`), и все контрольные числа совпадают с обычным запуском — потерь и двойного счёта нет.

Вывод: `logs/03_mapreduce_fail.txt`

```
[!] маппер упал: имитация отказа маппера на чанке 5 -> перезапуск чанка 5 (попытка 2)
=== MAPREDUCE | вариант: аналитики ===
строк в объекте: 73522, вакансий варианта: 54607, с навыками: 33662
k=1 навыки  уникальных:      9219   всего вхождений:     231229
k=2 пары    уникальных:    157717   всего вхождений:    1004033
k=3 тройки  уникальных:   1116083   всего вхождений:    3872336
проверка: Σ C(n,2) = 1004033, Σ C(n,3) = 3872336

Топ-10 навыков:
   10653  SQL
    8157  Аналитическое мышление
    6464  BPMN
    5894  Бизнес-анализ
    5226  Системный анализ
    5062  Анализ данных
    4767  UML
    4452  Разработка технических заданий
    4305  Работа с большим объемом информации
    3877  MS Excel
```

```
Топ-10 пар:
    3880  BPMN + UML
    2966  BPMN + SQL
    2681  SQL + UML
    2671  Python + SQL
    2507  Анализ данных + Аналитическое мышление
    2442  SQL + Системный анализ
    2238  BPMN + Системный анализ
    2236  Аналитическое мышление + Работа с большим объемом информации
    2055  UML + Системный анализ
    2050  SQL + Аналитическое мышление

Топ-10 троек:
    2201  BPMN + SQL + UML
    1699  BPMN + UML + Системный анализ
    1387  BPMN + REST + UML
    1266  BPMN + SQL + Системный анализ
    1236  SQL + UML + Системный анализ
    1213  REST + SQL + UML
    1186  BPMN + REST + SQL
    1012  REST + SOAP + SQL
    1002  Анализ данных + Аналитическое мышление + Работа с большим объемом информации
     933  BPMN + UML + Бизнес-анализ

 {'chunk_mb': 8, 'workers': 4, 'chunks': 34, 'retries': 1, 'seconds': 6.64}
```

3.3. Рост числа сочетаний

Уникальных навыков 9 219, пар — уже 157 717 (×17), троек — 1 116 083 (ещё ×7). Число вхождений растёт так же: 231 229 → 1 004 033 → 3 872 336. Причина — комбинаторика внутри вакансии: вакансия с n навыками даёт C(n,2) = n(n−1)/2 пар и C(n,3) = n(n−1)(n−2)/6 троек, т.е. пары растут как n^2, тройки — как n^3. В среднем у вакансии с навыками 231 229 / 33 662 ≈ 6,9 навыка (C(7,2) = 21 пара, C(7,3) = 35 троек), а hh.ru разрешает до 30 навыков: 123 вакансии с 30 навыками дают по C(30,3) = 4 060 троек каждая, т.е. ~0,5 млн вхождений — 13 % всех троек. Это проверено точно: по распределению числа навыков Σ C(n,2) = 1 004 033 и Σ C(n,3) = 3 872 336 — ровно столько вхождений пар и троек насчитал MapReduce (строка «проверка» в выводе).

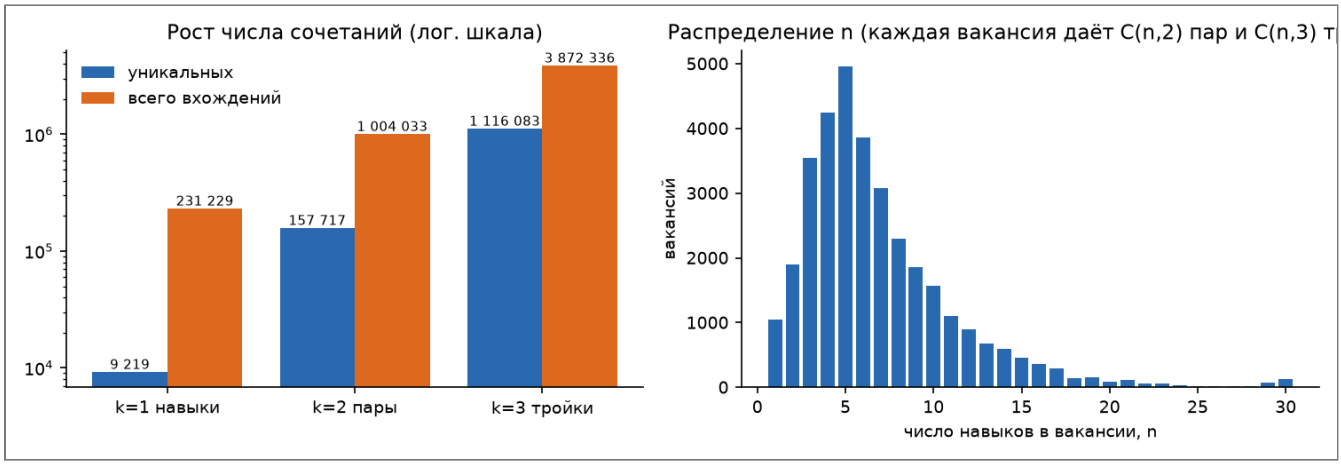


Рис. 3. Рост числа сочетаний и распределение числа навыков в вакансии

3.4. DuckDB (`duckdb_skills.py`)

DuckDB читает тот же объект напрямую из RustFS через расширение `httpfs` (S3-секрет с endpoint `localhost:9000`, path-style). Условие варианта и нормализация навыков написаны на SQL:

```
SELECT vacancy_id AS rid,
       list_distinct(list_filter(
           list_transform(string_split(coalesce(key_skills, ''), ';'), x -> trim(x)),
           x -> x <> '')) AS skills
FROM read_csv('s3://hh-lake/raw/hh_analysts_2024.csv', header=true, all_varchar=true, ...)
WHERE role IN ('Аналитик', 'BI-аналитик, аналитик данных', 'Бизнес-аналитик',
               'Системный аналитик', 'Продуктовый аналитик');

-- e(rid, s) = unnest(skills); пары и тройки — self-join по вакансии с упорядочиванием навыков
SELECT a.s, b.s, count(*) FROM e a JOIN e b ON a.rid = b.rid AND a.s < b.s GROUP BY ALL;
```

```
SELECT a.s, b.s, c.s, count(*) FROM e a JOIN e b ON a.rid = b.rid AND a.s < b.s
                                    JOIN e c ON b.rid = c.rid AND b.s < c.s GROUP BY ALL;
```

Условие `a.s < b.s < c.s` — SQL-аналог `combinations()` от отсортированного списка: каждое сочетание считается один раз. Результаты k = 1, 2, 3 тоже лежат в бакете (`results/duckdb/`).

Вывод: `logs/04_duckdb.txt`

```
[   0.0 с] httpfs подключён, читаю CSV из S3
[   2.4 с] вакансии варианта загружены
[   2.4 с] k=1 посчитано
[   2.5 с] k=2 посчитано
[   2.9 с] k=3 посчитано
[   5.1 с] контрольные числа посчитаны
[   5.4 с] k1_skills.csv сохранён в S3 и локально
[   5.7 с] k2_pairs.csv сохранён в S3 и локально
[   7.4 с] k3_triples.csv сохранён в S3 и локально
=== DUCKDB (opt) | вариант: аналитики ===
строк в объекте: 73522, вакансий варианта: 54607, с навыками: 33662
k=1 навыки  уникальных:      9219   всего вхождений:     231229
k=2 пары    уникальных:    157717   всего вхождений:    1004033
k=3 тройки  уникальных:   1116083   всего вхождений:    3872336

Топ-10 навыков:
   10653  SQL
    8157  Аналитическое мышление
    6464  BPMN
    5894  Бизнес-анализ
    5226  Системный анализ
    5062  Анализ данных
    4767  UML
    4452  Разработка технических заданий
    4305  Работа с большим объемом информации
    3877  MS Excel

Топ-10 пар:
    3880  BPMN + UML
    2966  BPMN + SQL
    2681  SQL + UML
    2671  Python + SQL
    2507  Анализ данных + Аналитическое мышление
    2442  SQL + Системный анализ
    2238  BPMN + Системный анализ
    2236  Аналитическое мышление + Работа с большим объемом информации
    2055  UML + Системный анализ
    2050  SQL + Аналитическое мышление

Топ-10 троек:
    2201  BPMN + SQL + UML
    1699  BPMN + UML + Системный анализ
    1387  BPMN + REST + UML
    1266  BPMN + SQL + Системный анализ
    1236  SQL + UML + Системный анализ
    1213  REST + SQL + UML
    1186  BPMN + REST + SQL
    1012  REST + SOAP + SQL
    1002  Анализ данных + Аналитическое мышление + Работа с большим объемом информации
     933  BPMN + UML + Бизнес-анализ

 {'mode': 'opt', 'seconds': 5.06}
```

4. Верификация результатов

`verify.py` читает результаты обоих способов *из хранилища* и сравнивает контрольные числа (строк в объекте, вакансий варианта, с навыками, уникальных и всего для k = 1, 2, 3, распределение числа навыков) и полностью — каждую строку каждой таблицы.

Вывод: `logs/05_verify.txt`

```
Объекты результатов в бакете:
  s3://hh-lake/results/analysis/regions_t1.csv                357 байт
  s3://hh-lake/results/analysis/regions_t2.csv              24300 байт
  s3://hh-lake/results/analysis/salary_added_effect.csv      4579 байт
  s3://hh-lake/results/analysis/salary_pair_up.csv          80888 байт
  s3://hh-lake/results/analysis/salary_triple_up.csv       271044 байт
  s3://hh-lake/results/duckdb/k1_skills.csv                309970 байт
```

```
  s3://hh-lake/results/duckdb/k2_pairs.csv                9656059 байт
  s3://hh-lake/results/duckdb/k3_triples.csv             104160012 байт
  s3://hh-lake/results/duckdb/summary.json                     733 байт
  s3://hh-lake/results/mapreduce/k1_skills.csv              319176 байт
  s3://hh-lake/results/mapreduce/k2_pairs.csv              9813113 байт
  s3://hh-lake/results/mapreduce/k3_triples.csv          105270366 байт
  s3://hh-lake/results/mapreduce/summary.json                  918 байт
  s3://hh-lake/results/mapreduce/x.txt                           5 байт
  s3://hh-lake/results/mapreduce_v2/k1_skills/part-00000.csv      77882 байт
  s3://hh-lake/results/mapreduce_v2/k1_skills/part-00001.csv      79696 байт
  s3://hh-lake/results/mapreduce_v2/k1_skills/part-00002.csv      79294 байт
  s3://hh-lake/results/mapreduce_v2/k1_skills/part-00003.csv      82343 байт
  s3://hh-lake/results/mapreduce_v2/k2_pairs/part-00000.csv    2455552 байт
  s3://hh-lake/results/mapreduce_v2/k2_pairs/part-00001.csv    2457532 байт
  s3://hh-lake/results/mapreduce_v2/k2_pairs/part-00002.csv    2455125 байт
  s3://hh-lake/results/mapreduce_v2/k2_pairs/part-00003.csv    2444967 байт
  s3://hh-lake/results/mapreduce_v2/k3_triples/part-00000.csv   26271036 байт
  s3://hh-lake/results/mapreduce_v2/k3_triples/part-00001.csv   26321485 байт
  s3://hh-lake/results/mapreduce_v2/k3_triples/part-00002.csv   26366906 байт
  s3://hh-lake/results/mapreduce_v2/k3_triples/part-00003.csv   26311026 байт
  s3://hh-lake/results/mapreduce_v2/summary.json               946 байт

контрольное число                mapreduce        duckdb  совпало
rows_in_object                       73522         73522  да
variant_vacancies                    54607         54607  да
with_skills                          33662         33662  да
навыки уникальных                     9219          9219  да
навыки вхождений                    231229        231229  да
пары уникальных                     157717        157717  да
пары вхождений                     1004033       1004033  да
тройки уникальных                  1116083       1116083  да
тройки вхождений                   3872336       3872336  да
распределение числа навыков                              да

Полное сравнение таблиц (каждая строка и каждое число):
  k=1: строк mapreduce=9219, duckdb=9219, расхождений: 0
  k=2: строк mapreduce=157717, duckdb=157717, расхождений: 0
  k=3: строк mapreduce=1116083, duckdb=1116083, расхождений: 0

ИТОГ: результаты ПОЛНОСТЬЮ СОВПАДАЮТ
```

```
(hw3) golubevamaria@MacBook-Air-Golubeva hw3 % python -u verify.py | tee logs/05_verify.txt
Объекты результатов в бакете:
  s3://hh-lake/results/duckdb/k1_skills.csv                309970 байт
  s3://hh-lake/results/duckdb/k2_pairs.csv                9656059 байт
  s3://hh-lake/results/duckdb/k3_triples.csv             104160012 байт
  s3://hh-lake/results/duckdb/summary.json                     733 байт
  s3://hh-lake/results/mapreduce/k1_skills.csv              319176 байт
  s3://hh-lake/results/mapreduce/k2_pairs.csv              9813113 байт
  s3://hh-lake/results/mapreduce/k3_triples.csv          105270366 байт
  s3://hh-lake/results/mapreduce/summary.json                  918 байт
  s3://hh-lake/results/mapreduce/x.txt                           5 байт

контрольное число                MapReduce         DuckDB  совпало
rows_in_object                       73522         73522  да
variant_vacancies                    54607         54607  да
with_skills                          33662         33662  да
навыки уникальных                     9219          9219  да
навыки вхождений                    231229        231229  да
пары уникальных                     157717        157717  да
пары вхождений                     1004033       1004033  да
тройки уникальных                  1116083       1116083  да
тройки вхождений                   3872336       3872336  да
распределение числа навыков                              да

Полное сравнение таблиц (каждая строка и каждое число):
  k=1: строк MR=9219, DuckDB=9219, расхождений: 0
  k=2: строк MR=157717, DuckDB=157717, расхождений: 0
  k=3: строк MR=1116083, DuckDB=1116083, расхождений: 0

ИТОГ: результаты ПОЛНОСТЬЮ СОВПАДАЮТ
(hw3) golubevamaria@MacBook-Air-Golubeva hw3 %
```

Рис. 4. Сверка: все контрольные числа и все 1 283 019 строк совпали

Итог: результаты MapReduce и DuckDB полностью совпадают — 9 219 навыков, 157 717 пар и 1 116 083 тройки, ни одного расхождения в счётчиках. Размеры CSV-файлов в бакете немного различаются (например, 9 813 113 и 9 656 059 байт для пар) только из-за форматирования: Python-модуль `csv` и

DuckDB по-разному решают, когда брать поле в кавычки; содержимое после разбора идентично, это и показывает построчная сверка.

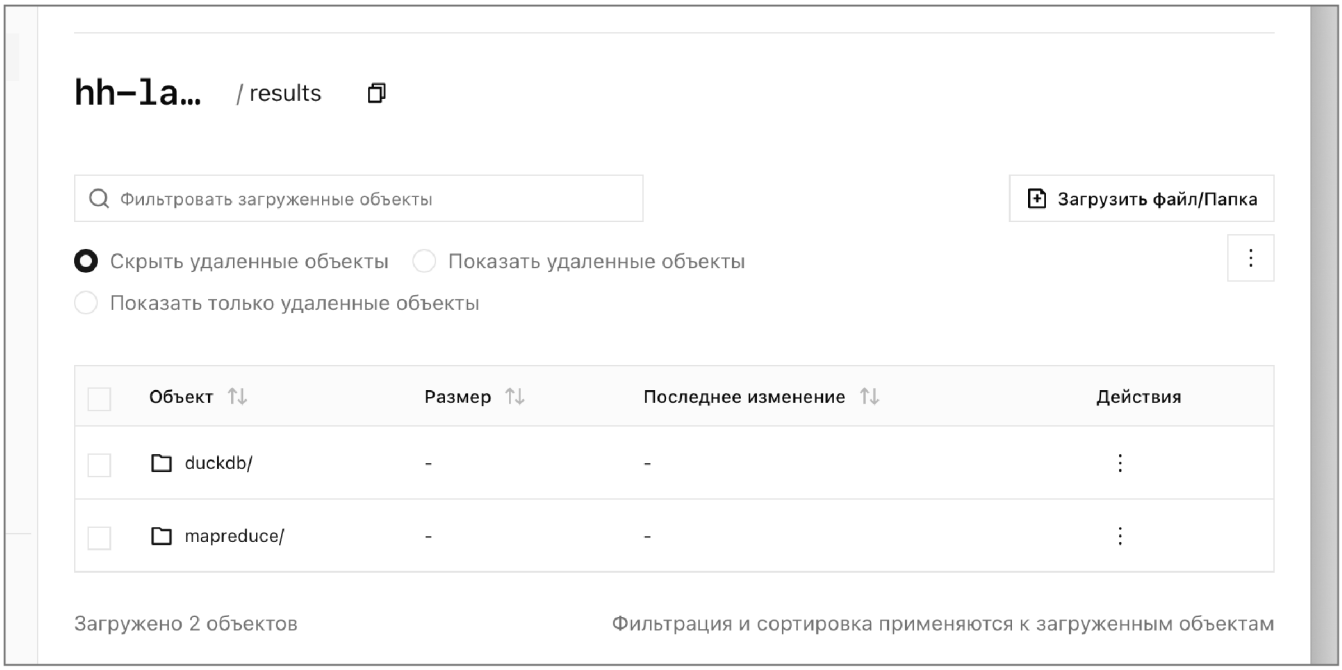


Рис. 5. Результаты обоих способов для k = 1, 2, 3 в бакете hh-lake/results

5. Влияние навыков на заработную плату

5.1. Методика

- **Зарплата** — только вакансии в рублях; середина вилки (или единственная указанная граница); если вилка «до вычета налогов» (`gross = true`), вычитается 13 % НДФЛ, чтобы все суммы были «на руки». Выбросы вне 15 тыс. – 1,5 млн ₽ отброшены. Зарплата указана у 18 674 из 54 607 вакансий (34 %).
- **Прибавка для пары (A, B):** база — *более частый* навык пары A (частота по всем вакансиям варианта); прибавка = медиана вакансий с A и B − медиана вакансий с A. Т.е. «что даёт добавление навыка B к распространённому навыку A».
- **Прибавка для тройки:** база — самая частая из трёх входящих в неё пар; добавка — оставшийся третий навык; прибавка = медиана тройки − медиана базовой пары.
- **Надёжность:** пара — не меньше 50 вакансий с зарплатой, тройка — не меньше 30, и в обоих случаях не меньше 10 разных работодателей.

Инсайт: вакансии-клоны искажают медианы. В моём первом прогоне все 10 «самых понижающих» пар выглядели как `REST + Agile`, `REST + Scrum`, `REST + JSON API`… с одной и той же медианой 65 250 ₽. Я проверила исходные данные: это один работодатель (id 6093775), который публикует одинаковую вакансию «Системный аналитик (стажёр)» с одной вилкой 70–80 тыс. ₽ до вычета налогов в десятках городов (Уфа, Екатеринбург, Омск, Томск, Краснодар, …). Фильтр «≥10 работодателей» проблему не решил: клоны составляют больше половины таких сочетаний, и медиана всё равно равна их зарплате. Поэтому для анализа зарплат я считаю одинаковые публикации (тот же работодатель, название, набор навыков и вилка) один раз: из 54 607 вакансий остаётся 38 722 уникальных публикации, из 18 674 с зарплатой — 13 750. В региональном анализе (п. 6) клоны оставлены — это реальные вакансии в разных городах. Вывод первого прогона сохранён в `logs/06_salary_before_employer_filter.txt`.

5.2. Результаты

Вывод: `logs/06_salary.txt`

```
Клоны вакансий: всего 54607, уникальных публикаций 38722 (убрано 15885); с зарплатой 18674 -> 13750
Вариант: аналитики. Зарплата: середина вилки в ₽ «на руки» (gross -13%)  15 000–1 500 000 ₽

### Общая картина
vacancies  with_salary  pct_salary  salary_and_skills  median_all  median_with_skills  median_no_skills
---------  -----------  ----------  -----------------  ----------  ------------------  ----------------
   54 607       18 674        34.2             12 333      93 960              95 178            90 000

Базовая медиана для сравнения навыков (уникальные публикации с навыками): 96 000 ₽

### Медиана по ролям
role                          vacancies  with_salary   median
----------------------------  ---------  -----------  -------
Системный аналитик               10 609        2 762  156 600
Бизнес-аналитик                   8 232        2 738  104 400
BI-аналитик, аналитик данных      3 969          986  100 000
Продуктовый аналитик              1 685          449  100 000
Аналитик                         30 112       11 739   80 000

### Навыки с самой высокой медианой (≥100 вакансий с зарплатой, ≥10 работодателей)
skill                    freq  n_salary  employers   median  delta_vs_all  delta_pct
----------------------  -----  --------  ---------  -------  ------------  ---------
SOAP                    1 659       257        127  230 000       134 000        140
REST                    2 526       392        182  220 000       124 000        129
API                     1 465       287        163  200 000       104 000        108
JSON                      953       188        109  200 000       104 000        108
XML                     1 418       257        143  200 000       104 000        108
1C: ERP                   377       108         71  197 875       101 875        106
UML                     4 767       824        408  191 700        95 700       99.7
JSON API                  856       133         78  190 000        94 000       97.9
ERP-системы на базе 1С  2 063       640        275  175 000        79 000       82.3
PostgreSQL              1 223       186        110  175 000        79 000       82.3
```

Навыки с самой низкой медианой

skill	freq	n_salary	employers	median	delta_vs_all	delta_pct
Пользователь ПК	367	211	148	50 000	−46 000	−47.9
Поиск информации в интернет	227	124	95	55 000	−41 000	−42.7
Google Docs	210	114	90	60 000	−36 000	−37.5
Многозадачность	238	100	69	60 000	−36 000	−37.5
Деловое общение	483	244	171	60 900	−35 100	−36.6
Обучение и развитие	519	221	148	60 900	−35 100	−36.6
Деловая переписка	610	324	235	64 000	−32 000	−33.3
Грамотность	283	129	97	65 000	−31 000	−32.3
Аналитический склад ума	861	308	217	65 250	−30 750	−32.0
Ответственность	290	137	102	65 250	−30 750	−32.0

ПАРЫ, сильнее всего ПОВЫШАЮЩИЕ медиану (база — более частый навык; ≥50 вакансий, ≥10 работодателей)

base	added	n_pair	employers	median_pair	n_base	median_base	uplift	uplift_pct
Сбор и анализ информации	ERP-системы на базе 1С	90	51	200 000	1 097	80 000	120 000	150
SQL	Системная интеграция	66	44	235 000	1 868	135 000	100 000	74.1
SQL	SOAP	199	96	225 000	1 868	135 000	90 000	66.7
SQL	Xsd	50	23	225 000	1 868	135 000	90 000	66.7
SQL	REST	274	124	222 500	1 868	135 000	87 500	64.8
Аналитическое мышление	ERP-системы на базе 1С	127	79	165 000	2 985	80 000	85 000	106
BPMN	SOAP	170	87	240 000	1 241	156 600	83 400	53.3
Постановка задач разработчикам	REST	66	44	230 000	1 049	150 000	80 000	53.3
SQL	DWH	62	34	208 750	1 868	135 000	73 750	54.6
Аналитика	ERP-системы на базе 1С	81	45	165 000	1 305	91 350	73 650	80.6

ПАРЫ, сильнее всего ПОНИЖАЮЩИЕ медиану

base	added	n_pair	employers	median_pair	n_base	median_base	uplift	uplift_pct
Системный анализ	Аналитические исследования	75	55	91 350	1 139	160 000	−68 650	−42.9
UML	Аналитика	80	53	130 000	824	191 700	−61 700	−32.2
UML	Базы данных	65	31	130 000	824	191 700	−61 700	−32.2
UML	Моделирование бизнес процессов	113	81	130 000	824	191 700	−61 700	−32.2
Системный анализ	Python	50	30	100 000	1 139	160 000	−60 000	−37.5
Разработка технических заданий	CRM	59	38	80 000	1 297	139 200	−59 200	−42.5
SQL	Информационные технологии	55	32	78 300	1 868	135 000	−56 700	−42.0
UML	Техническая документация	79	45	135 000	824	191 700	−56 700	−29.6
BPMN	Деловая коммуникация	62	37	100 000	1 241	156 600	−56 600	−36.1
BPMN	CRM	54	29	106 575	1 241	156 600	−50 025	−31.9

ТРОЙКИ, сильнее всего ПОВЫШАЮЩИЕ медиану (база — самая частая пара внутри; ≥30 вакансий, ≥10 работодателей)

base_pair	added	n_triple	employers	median_triple	n_base	median_base	uplift	uplift_pct
Аналитика + Сбор и анализ информации	ERP-системы на базе 1С	30	19	200 000	451	85 000	115 000	135
BPMN + SQL	Kafka	35	19	295 000	517	191 400	103 600	54.1
BPMN + UML	Kafka	40	22	297 500	669	195 000	102 500	52.6
Python + SQL	A/B тесты	33	23	220 000	423	120 000	100 000	83.3
SQL + UML	Kafka	35	19	300 000	461	200 000	100 000	50.0
SQL + Базы данных	XML	37	18	195 000	268	104 618	90 382	86.4
Аналитическое мышление + Сбор и анализ информации	ERP-системы на базе 1С	31	20	165 300	632	75 000	90 300	120
SQL + Постановка задач разработчикам	JSON	35	23	250 000	256	160 000	90 000	56.3

```
BPMN + Постановка задач разработчикам                    JSON                           33         24        240 000
287      150 075   89 925        59.9
Аналитическое мышление + Моделирование бизнес процессов  ERP-системы на базе 1С        36         22        195 700
245      115 000   80 700        70.2

### ТРОЙКИ, сильнее всего ПОНИЖАЮЩИЕ медиану
base_pair               added                         n_triple  employers  median_triple  n_base  median_base
uplift  uplift_pct
----------------------  ----------------------------  --------  ---------  -------------  ------  -----------  -----
---  ----------
SQL + Системный анализ  Информационные технологии           32         13         74 150     460      180 000  -105
850       -58.8
REST + SOAP             Аналитическое мышление              31         15        125 000     206      230 000  -105
000       -45.7
BPMN + REST             Базы данных                         31         13        135 000     255      230 000   -95
000       -41.3
BPMN + REST             Техническая документация            32         18        135 000     255      230 000   -95
000       -41.3
REST + UML              Техническая документация            37         17        135 000     261      230 000   -95
000       -41.3
BPMN + SQL              Python                              45         24        100 000     517      191 400   -91
400       -47.8
BPMN + UML              Оптимизация бизнес-процессов        40         24        106 875     669      195 000   -88
125       -45.2
REST + SQL              Техническая документация            30         15        135 000     274      222 500   -87
500       -39.3
REST + SOAP             Бизнес-анализ                       39         19        143 550     206      230 000   -86
450       -37.6
REST + SQL              Базы данных                         32         13        140 000     274      222 500   -82
500       -37.1

### ИТОГ: навыки, которые как ДОБАВКА к паре/тройке чаще всего ПОВЫШАЮТ зарплату (≥5 сочетаний)
skill                  combos  median_uplift_pct  combos_up  combos_down
---------------------  ------  -----------------  ---------  -----------
ERP-системы на базе 1С      22               49.0         22            0
BPMN                        13               41.8         11            1
Kafka                        6               39.6          6            0
REST API                     7               27.7          7            0
Data Analysis                6               27.7          6            0
REST                        24               27.5         24            0
Tableau                      5               25.0          4            0
MS SQL                      40               25.0         34            5
Системный анализ            31               23.4         27            3
Английский язык             14               23.4         13            1

### ИТОГ: навыки, которые как ДОБАВКА чаще всего ПОНИЖАЮТ зарплату
skill                         combos  median_uplift_pct  combos_up  combos_down
----------------------------  ------  -----------------  ---------  -----------
CRM                                8              -31.9          0            8
Обучение и развитие                6              -26.8          0            6
Поиск информации в интернет        5              -25.4          0            5
Аналитическое мышление            17              -22.7          0           17
Информационные технологии         14              -20.6          0           13
Анализ требований                  5              -17.4          0            5
Анализ данных                     27              -16.7          0           24
Деловая переписка                 14              -14.9          4           10
MS Excel                          24              -13.2          0           24
Работа с базами данных            57              -12.5          3           50

Сохранено в s3://hh-lake/results/analysis/  за 4.4 с
```

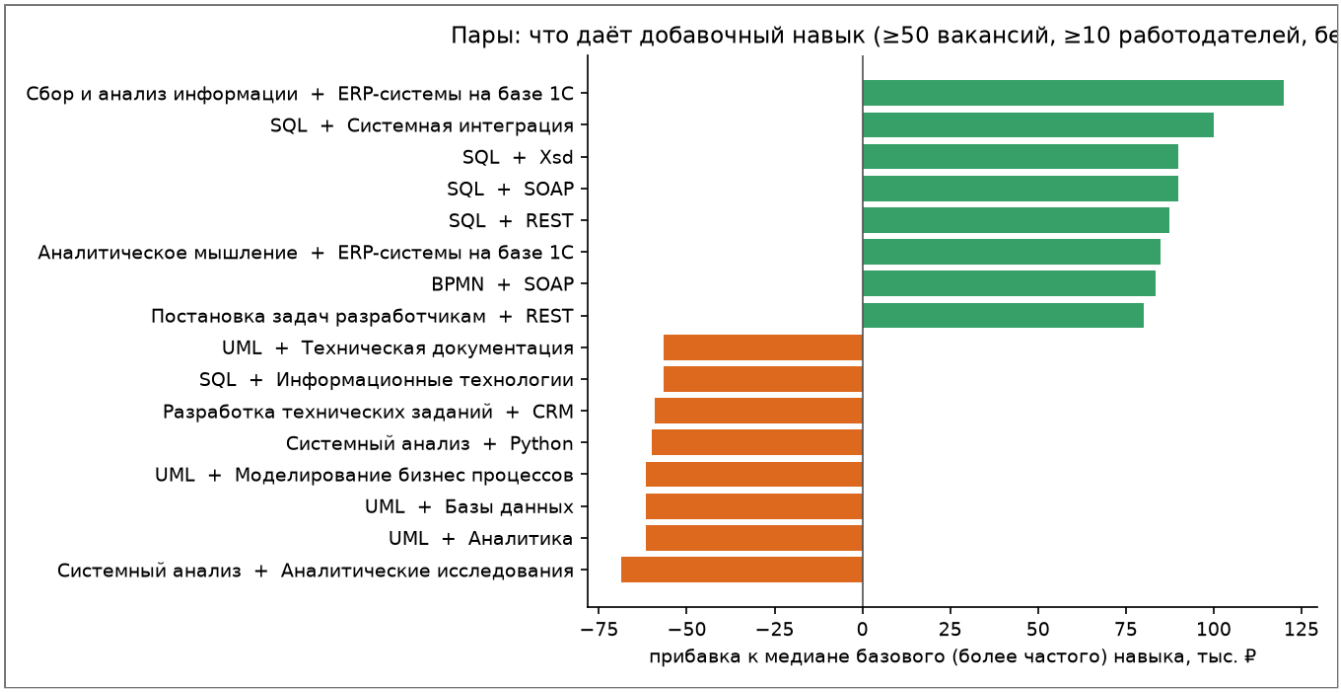


Рис. 6. Прибавка от добавочного навыка к медиане базового навыка пары

5.3. Интерпретация

Повышают зарплату конкретные технологии интеграции и данных — признак системного аналитика, работающего вплотную с разработкой:

- Интеграционный стек **REST, SOAP, XML, JSON, API** — медиана 200–230 тыс. ₽ при базовой 96 тыс. ₽ (+108…+140 %). Добавление SOAP или REST к SQL поднимает медиану со 135 до 222–225 тыс. ₽ (+65…+67 %), REST к «Постановке задач разработчикам» — со 150 до 230 тыс. ₽.
- **Kafka** — самая «дорогая» добавка: к тройкам BPMN+SQL, BPMN+UML, SQL+UML она даёт +100…+104 тыс. ₽, медианы 295–300 тыс. ₽. Это аналитики high-load систем с асинхронной интеграцией.
- **ERP-системы на базе 1С** — повышают в 22 из 22 сочетаний (медиана прибавки +49 %): общий навык «Сбор и анализ информации» стоит 80 тыс. ₽, а вместе с ERP на 1С — 200 тыс. ₽. Аналитик внедрения ERP — узкая и хорошо оплачиваемая специализация.
- **DWH** к SQL (+74 тыс. ₽) и **A/B-тесты** к Python+SQL (со 120 до 220 тыс. ₽, +83 %) — продуктовая аналитика и хранилища данных ценятся выше «просто SQL».
- В итоговой таблице добавок также повышают BPMN, REST API, MS SQL, Tableau, «Системный анализ», английский язык.

Понижают зарплату общие и «офисные» навыки:

- Самые низкие медианы у навыков «Пользователь ПК» (50 тыс. ₽, −48 % к базе), «Поиск информации в интернет», Google Docs, «Многозадачность», «Деловая переписка», «Грамотность» — так описывают позиции начального уровня и околоаналитическую офисную работу, а не IT-аналитику.
- Как добавка **MS Excel** понижает медиану в 24 из 24 сочетаний, «Аналитическое мышление» — в 17 из 17, «Анализ данных» — в 24 из 27, «Работа с базами данных» — в 50 из 57, **CRM** — в 8 из 8 (−32 %). Работодатели высокооплачиваемых вакансий пишут конкретные технологии (PostgreSQL, MS SQL, DWH), а общие формулировки типичны для junior-позиций и небольших компаний.
- Неожиданный пример — **Python**: к «Системному анализу» он снижает медиану со 160 до 100 тыс. ₽, к BPMN+SQL — со 191 до 100 тыс. ₽ (−48 %). Python в такой вакансии означает смещение от системного

аналитика (интеграции, ТЗ) к аналитику данных начального уровня, которому платят меньше: по ролям медиана системного аналитика 157 тыс. ₽, «аналитика» — 80 тыс. ₽.

- Теги «Информационные технологии», «Аналитические исследования», «Техническая документация» в сочетании с сильными навыками тоже снижают медиану на 30–59 %: их чаще ставят работодатели, заполняющие навыки по шаблону.

Это корреляции, а не причинность: навык показывает, к какому типу вакансии она относится (системный аналитик / аналитик данных / офисная позиция), а уровень оплаты в первую очередь определяется ролью, опытом и городом.

6. Региональный анализ

Я выбрала три крупнейших по числу вакансий аналитиков региона: Москва, Санкт-Петербург и Екатеринбург. Скрипт `regions.py` считает две таблицы: (1) ключевые показатели (объём, доля зарплат, квартильные зарплаты, удалёнка, вакансии без опыта, навыки) и (2) топ навыков, **пар и троек** с долей от вакансий с навыками и медианой зарплаты; плюс структура по ролям, медианы по опыту и характерные навыки региона.

Вывод: `logs/07_regions.txt`

```
### Топ регионов по числу вакансий аналитиков (выбраны первые три)
region           vacancies
---------------  ---------
Москва              26 726
Санкт-Петербург      5 793
Екатеринбург         2 203
Казань               1 409
Новосибирск          1 386
Нижний Новгород      1 230
Краснодар            1 055
Самара                 815

### Таблица 1. Ключевые показатели регионов (зарплата на руки, ₽)
region           vacancies  pct_of_russia  pct_with_salary      p25   median      p75  pct_remote  pct_no_exp
pct_with_skills  avg_skills
---------------  ---------  -------------  ---------------  -------  -------  -------  ----------  ----------  -----
----------  ----------
Москва              26 726           48.9             24.2  100 000  150 000  215 000        24.3         6.0
60.3         6.7
Санкт-Петербург      5 793           10.6             32.3   75 000  110 000  160 000        24.7         9.0
64.8         6.8
Екатеринбург         2 203            4.0             40.6   60 000   80 000  119 500        25.0        11.2
60.5         6.7

### Структура по ролям (число вакансий)
role                          Москва  Санкт-Петербург  Екатеринбург
----------------------------  ------  ---------------  ------------
Аналитик                      13 280            3 005         1 223
Системный аналитик             5 821            1 206           446
Бизнес-аналитик                4 236              953           319
BI-аналитик, аналитик данных   2 338              430           148
Продуктовый аналитик           1 051              199            67

### Медианная зарплата по опыту
experience           Москва  Санкт-Петербург  Екатеринбург
-------------------  -------  ---------------  ------------
Нет опыта             66 375           60 000        55 000
От 1 года до 3 лет   120 000          100 000        80 000
От 3 до 6 лет        210 000          170 000       130 250
Более 6 лет          250 000          235 000       170 000

### Таблица 2.1. Топ-10 навыков: Москва (доля от вакансий с навыками, %)
rnk  combo                            cnt   pct  median_salary
---  -------------------------------  -----  ----  -------------
  1  SQL                            6 056  37.6        174 000
  2  BPMN                           3 470  21.5        200 000
  3  Аналитическое мышление         2 997  18.6        120 000
  4  Бизнес-анализ                  2 705  16.8        154 425
  5  Системный анализ               2 654  16.5        200 000
  6  UML                            2 604  16.2        217 500
  7  Анализ данных                  2 237  13.9        120 000
  8  Python                         2 090  13.0        150 000
  9  MS Excel                       1 840  11.4        100 000
 10  Разработка технических заданий  1 771  11.0        191 400
```

Таблица 2.1. Топ-10 навыков: Санкт-Петербург (доля от вакансий с навыками, %)

rnk	combo	cnt	pct	median_salary
1	SQL	1 144	30.5	125 000
2	Аналитическое мышление	871	23.2	100 000
3	Бизнес-анализ	749	20.0	120 000
4	BPMN	744	19.8	138 730
5	Системный анализ	615	16.4	150 000
6	UML	559	14.9	150 000
7	Разработка технических заданий	520	13.9	150 000
8	Анализ данных	486	12.9	106 288
9	Постановка задач разработчикам	441	11.8	150 000
10	Аналитика	409	10.9	115 000

Таблица 2.1. Топ-10 навыков: Екатеринбург (доля от вакансий с навыками, %)

rnk	combo	cnt	pct	median_salary
1	Аналитическое мышление	392	29.4	75 000
2	SQL	367	27.6	104 400
3	Бизнес-анализ	264	19.8	90 000
4	BPMN	254	19.1	120 000
5	Анализ данных	247	18.5	70 000
6	Разработка технических заданий	212	15.9	115 000
7	Системный анализ	200	15.0	120 000
8	Работа с большим объемом информации	186	14.0	73 000
9	Аналитика	178	13.4	70 000
10	Постановка задач разработчикам	163	12.2	130 500

Таблица 2.2. Топ-10 пар: Москва (доля от вакансий с навыками, %)

rnk	combo	cnt	pct	median_salary
1	BPMN + UML	2 166	13.4	225 000
2	Python + SQL	1 689	10.5	150 000
3	BPMN + SQL	1 570	9.7	220 000
4	SQL + UML	1 422	8.8	225 000
5	SQL + Системный анализ	1 297	8.1	200 000
6	BPMN + Системный анализ	1 167	7.2	217 500
7	UML + Системный анализ	1 098	6.8	225 000
8	SQL + Анализ данных	994	6.2	150 000
9	REST + SQL	970	6.0	247 500
10	Анализ данных + Аналитическое мышление	960	6.0	113 100

Таблица 2.2. Топ-10 пар: Санкт-Петербург (доля от вакансий с навыками, %)

rnk	combo	cnt	pct	median_salary
1	BPMN + UML	454	12.1	150 000
2	BPMN + SQL	348	9.3	135 000
3	SQL + UML	328	8.7	150 000
4	Python + SQL	318	8.5	105 000
5	SQL + Системный анализ	300	8.0	145 000
6	BPMN + Системный анализ	288	7.7	137 460
7	BPMN + Бизнес-анализ	261	7.0	120 000
8	UML + Системный анализ	259	6.9	165 000
9	Постановка задач разработчикам + Разработка технических заданий	244	6.5	150 000
10	Анализ данных + Аналитическое мышление	241	6.4	106 288

Таблица 2.2. Топ-10 пар: Екатеринбург (доля от вакансий с навыками, %)

rnk	combo	cnt	pct	median_salary
1	Анализ данных + Аналитическое мышление	136	10.2	69 000
2	BPMN + UML	117	8.8	162 500
3	SQL + Аналитическое мышление	110	8.3	76 700
4	Аналитическое мышление + Работа с большим объемом информации	109	8.2	76 700
5	Аналитическое мышление + Бизнес-анализ	107	8.0	80 000
6	BPMN + SQL	103	7.7	150 000
7	Постановка задач разработчикам + Разработка технических заданий	99	7.4	120 000
8	BPMN + Системный анализ	97	7.3	120 000
9	SQL + Анализ данных	96	7.2	75 850
10	BPMN + Бизнес-анализ	93	7.0	100 000

Таблица 2.3. Топ-10 троек: Москва (доля от вакансий с навыками, %)

rnk	combo	cnt	pct	median_salary
1	BPMN + SQL + UML	1 191	7.4	235 000
2	BPMN + UML + Системный анализ	899	5.6	239 250
3	BPMN + REST + UML	797	4.9	250 000
4	BPMN + SQL + Системный анализ	661	4.1	220 000
5	BPMN + REST + SQL	654	4.1	250 000
6	REST + SQL + UML	652	4.0	243 050
7	SQL + UML + Системный анализ	635	3.9	221 850
8	REST + SOAP + SQL	531	3.3	245 000
9	BPMN + SOAP + UML	520	3.2	261 000
10	BPMN + REST + SOAP	491	3.0	259 260

Таблица 2.3. Топ-10 троек: Санкт-Петербург (доля от вакансий с навыками, %)

rnk	combo	cnt	pct	median_salary

1	BPMN + SQL + UML	269	7.2	150 000
2	BPMN + UML + Системный анализ	214	5.7	162 500
3	BPMN + SQL + Системный анализ	176	4.7	125 000
4	SQL + UML + Системный анализ	176	4.7	145 000
5	BPMN + REST + UML	157	4.2	147 900
6	REST + SQL + UML	145	3.9	140 000
7	BPMN + REST + SQL	143	3.8	135 000
8	BPMN + UML + Бизнес-анализ	135	3.6	120 000
9	BPMN + SOAP + UML	113	3.0	144 855
10	REST + SOAP + SQL	112	3.0	135 000

Таблица 2.3. Топ-10 троек: Екатеринбург (доля от вакансий с навыками, %)

rnk	combo	cnt	pct	median_salary
1	BPMN + SQL + UML	68	5.1	175 000
2	BPMN + UML + Системный анализ	64	4.8	82 650
3	SQL + Анализ данных + Аналитическое мышление	60	4.5	74 000
4	Постановка задач разработчикам + Разработка технических заданий + Системный анализ	55	4.1	160 000
5	Анализ данных + Аналитическое мышление + Работа с большим объемом информации	53	4.0	66 500
6	BPMN + SQL + Системный анализ	51	3.8	120 000
7	BPMN + Разработка технических заданий + Системный анализ	48	3.6	195 000
8	Анализ данных + Аналитика + Аналитическое мышление	48	3.6	60 000
9	SQL + UML + Системный анализ	42	3.2	73 950
10	Анализ данных + Аналитическое мышление + Сбор и анализ информации	42	3.2	60 000

Доля вакансий с навыком, % (топ-15 навыков трёх регионов)

skill	Москва	Санкт-Петербург	Екатеринбург
SQL	37.6	30.5	27.6
BPMN	21.5	19.8	19.1
Аналитическое мышление	18.6	23.2	29.4
Бизнес-анализ	16.8	20.0	19.8
Системный анализ	16.5	16.4	15.0
UML	16.2	14.9	10.9
Анализ данных	13.9	12.9	18.5
Python	13.0	10.2	8.9
MS Excel	11.4	9.1	10.4
Разработка технических заданий	11.0	13.9	15.9
Аналитика	10.7	10.9	13.4
Работа с большим объемом информации	10.3	9.9	14.0
Постановка задач разработчикам	9.6	11.8	12.2
REST	9.1	7.0	4.7
Моделирование бизнес процессов	6.3	9.5	8.9

Характерные навыки региона: доля здесь / доля в двух других (lift), навыки с долей ≥3%

region	skill	pct_here	pct_other_two	lift
Москва	MS PowerPoint	6.1	4.0	1.5
Москва	Подготовка презентаций	3.2	2.1	1.5
Москва	PostgreSQL	4.6	3.1	1.5
Москва	REST	9.1	6.4	1.4
Москва	SOAP	5.9	4.4	1.3
Санкт-Петербург	ERP	3.2	1.8	1.8
Санкт-Петербург	Техническая документация	3.6	2.0	1.8
Санкт-Петербург	1С: Предприятие 8	5.3	3.1	1.7
Санкт-Петербург	Системное мышление	3.0	1.8	1.7
Санкт-Петербург	1С: Управление Торговлей	3.0	1.8	1.7
Екатеринбург	Аналитический склад ума	4.0	1.7	2.4
Екатеринбург	Работа в команде	5.0	2.4	2.1
Екатеринбург	Анализ бизнес показателей	5.3	3.3	1.6
Екатеринбург	Техническая документация	3.5	2.2	1.6
Екатеринбург	Автоматизация процессов	4.1	2.7	1.5

Сохранено в s3://hh-lake/results/analysis/ за 3.8 с

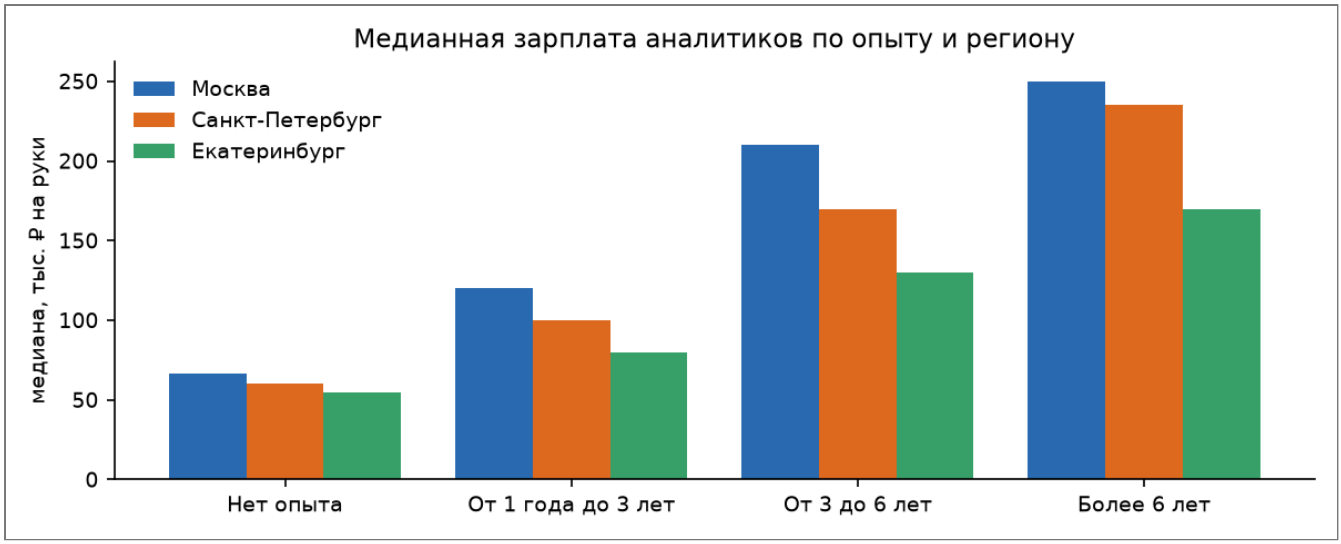


Рис. 7. Медианная зарплата по опыту

Наблюдения и инсайты

- **Москва — половина рынка.** 48,9 % всех вакансий IT-аналитиков России; Петербург — 10,6 %, Екатеринбург — 4 %. Москва в 4,6 раза больше Петербурга.
- **Зарплатный разрыв:** медиана 150 / 110 / 80 тыс. ₽ — Петербург на 27 %, Екатеринбург на 47 % ниже Москвы. Разрыв растёт с опытом в рублях: без опыта 66 / 60 / 55 тыс. ₽ (почти одинаково), 3–6 лет — 210 / 170 / 130 тыс. ₽. Для начинающих город почти не важен, для опытных — критичен.
- **Прозрачность зарплат обратна размеру рынка:** зарплату указывают 24 % московских вакансий, 32 % петербургских и 41 % екатеринбургских. В Москве крупные работодатели чаще пишут «по договорённости», поэтому реальная московская медиана, скорее всего, ещё выше.
- **Удалёнка одинакова — ~25 %** во всех трёх городах, а вакансий без опыта в регионах больше (6,0 / 9,0 / 11,2 %): в Екатеринбурге проще войти в профессию.
- **Москва технологичнее.** SQL требуют в 37,6 % московских вакансий против 30,5 % и 27,6 %; Python — 13,0 / 10,2 / 8,9 %; REST — 9,1 / 7,0 / 4,7 %; UML — 16,2 / 14,9 / 10,9 %. В Екатеринбурге навык №1 — «Аналитическое мышление» (29,4 %), выше доли «Анализ данных» и «Работа с большим объёмом информации» — те самые общие навыки с низкой медианой (70–75 тыс. ₽). То есть региональный разрыв в зарплатах — это не только «география», но и **разный состав вакансий**: в Москве больше системных аналитиков с интеграционным стеком.
- **Тройки показывают разницу ещё ярче:** в Москве весь топ-10 троек — технический стек системного аналитика (BPMN/UML/SQL/REST/SOAP) с медианами 220–261 тыс. ₽; в Екатеринбурге в топ-10 троек входят «Анализ данных + Аналитическое мышление + Работа с большим объемом информации» (66,5 тыс. ₽) и «Анализ данных + Аналитика + Аналитическое мышление» (60 тыс. ₽).
- **Один и тот же навык стоит по-разному:** SQL — 174 / 125 / 104 тыс. ₽, тройка BPMN+SQL+UML — 235 / 150 / 175 тыс. ₽ (здесь Екатеринбург даже обгоняет Петербург).
- **Специализации городов (lift — во сколько раз доля навыка выше, чем в двух других городах):** Петербург выделяется 1С (1С: Предприятие 8, 1С: Управление торговлей, ERP — lift 1,7–1,8) — много вакансий аналитиков внедрения 1С; Москва — презентациями (MS PowerPoint, «Подготовка презентаций», lift 1,5: консалтинг и корпоративный сектор) и интеграциями (REST, SOAP, PostgreSQL); Екатеринбург — «Аналитический склад ума», «Работа в команде», «Анализ бизнес-показателей» — общие формулировки.

7. Профилирование и оптимизация (бонус)

Каждый вариант запускается скриптом `profile_runs.py` отдельным процессом **3 раза**; измеряются время и пик памяти (максимум суммарного RSS процесса и всех дочерних процессов, опрос каждые 20 мс через psutil). Сохранение результатов при замерах отключено, чтобы мерить только вычисления. Для бонуса я сделала оптимизированную версию MapReduce — `mapreduce_v2.py`: мапперы сами читают свои диапазоны байтов из S3, shuffle выполняется внутри маппера, выход маппера сохраняется на диск, а 4 параллельных редьюсера сами пишут свои части результата в бакет (`results/mapreduce_v2/k*/part-0000N.csv`). Её результат я тоже сверила с DuckDB — полное совпадение (`logs/10_verify_v2.txt`), отказ маппера обрабатывается так же (`logs/09_mapreduce_v2_fail.txt`).

Вывод: `logs/08_profile.txt`

```
CPU: 8 ядер, RAM: 8 ГБ, Python 3.14.8

MR baseline (1 worker, 1 MB)     попытка 1:  10.12 с   пик памяти   547.4 МБ
MR baseline (1 worker, 1 MB)     попытка 2:   9.75 с   пик памяти   590.7 МБ
MR baseline (1 worker, 1 MB)     попытка 3:   9.54 с   пик памяти   562.0 МБ

MR optimized (4 workers, 8 MB)   попытка 1:   9.94 с   пик памяти   916.3 МБ
MR optimized (4 workers, 8 MB)   попытка 2:   8.81 с   пик памяти   804.1 МБ
MR optimized (4 workers, 8 MB)   попытка 3:   8.39 с   пик памяти   873.2 МБ

MR 4 workers, 32 MB              попытка 1:   7.99 с   пик памяти  1137.0 МБ
MR 4 workers, 32 MB              попытка 2:   8.14 с   пик памяти  1293.6 МБ
MR 4 workers, 32 MB              попытка 3:   8.26 с   пик памяти  1367.2 МБ

MR v2 (4 workers, 8 MB)          попытка 1:   3.51 с   пик памяти   952.8 МБ
MR v2 (4 workers, 8 MB)          попытка 2:   3.44 с   пик памяти   951.3 МБ
MR v2 (4 workers, 8 MB)          попытка 3:   3.57 с   пик памяти   954.2 МБ

DuckDB naive                     попытка 1:  12.02 с   пик памяти  1701.8 МБ
DuckDB naive                     попытка 2:  12.73 с   пик памяти  1910.4 МБ
DuckDB naive                     попытка 3:  12.94 с   пик памяти  1741.4 МБ

DuckDB opt                       попытка 1:   5.17 с   пик памяти  1819.9 МБ
DuckDB opt                       попытка 2:   5.20 с   пик памяти  1798.3 МБ
DuckDB opt                       попытка 3:   5.34 с   пик памяти  1898.5 МБ

вариант                            время, с (ср ± σ)   пик памяти ср, МБ  макс, МБ
-------------------------------------------------------------------------------------
MR baseline (1 worker, 1 MB)            9.80 ± 0.24               566.7     590.7
MR optimized (4 workers, 8 MB)          9.04 ± 0.66               864.5     916.3
MR 4 workers, 32 MB                     8.13 ± 0.11              1265.9    1367.2
MR v2 (4 workers, 8 MB)                 3.50 ± 0.05               952.8     954.2
DuckDB naive                           12.57 ± 0.39              1784.5    1910.4
DuckDB opt                              5.23 ± 0.07              1838.9    1898.5

сохранено в results/profile.json
```

```
(hw3) golubevamaria@MacBook-Air-Golubeva hw3 % clear; cat logs/08_profile.txt

CPU: 8 ядер, RAM: 8 ГБ, Python 3.14.8

MR baseline (1 worker, 1 MB)     попытка 1:  10.12 с   пик памяти   547.4 МБ
MR baseline (1 worker, 1 MB)     попытка 2:   9.75 с   пик памяти   590.7 МБ
MR baseline (1 worker, 1 MB)     попытка 3:   9.54 с   пик памяти   562.0 МБ

MR optimized (4 workers, 8 MB)   попытка 1:   9.94 с   пик памяти   916.3 МБ
MR optimized (4 workers, 8 MB)   попытка 2:   8.81 с   пик памяти   804.1 МБ
MR optimized (4 workers, 8 MB)   попытка 3:   8.39 с   пик памяти   873.2 МБ

MR 4 workers, 32 MB              попытка 1:   7.99 с   пик памяти  1137.0 МБ
MR 4 workers, 32 MB              попытка 2:   8.14 с   пик памяти  1293.6 МБ
MR 4 workers, 32 MB              попытка 3:   8.26 с   пик памяти  1367.2 МБ

MR v2 (4 workers, 8 MB)          попытка 1:   3.51 с   пик памяти   952.8 МБ
MR v2 (4 workers, 8 MB)          попытка 2:   3.44 с   пик памяти   951.3 МБ
MR v2 (4 workers, 8 MB)          попытка 3:   3.57 с   пик памяти   954.2 МБ

DuckDB naive                     попытка 1:  12.02 с   пик памяти  1701.8 МБ
DuckDB naive                     попытка 2:  12.73 с   пик памяти  1910.4 МБ
DuckDB naive                     попытка 3:  12.94 с   пик памяти  1741.4 МБ

DuckDB opt                       попытка 1:   5.17 с   пик памяти  1819.9 МБ
DuckDB opt                       попытка 2:   5.20 с   пик памяти  1798.3 МБ
DuckDB opt                       попытка 3:   5.34 с   пик памяти  1898.5 МБ

вариант                            время, с (ср ± σ)   пик памяти ср, МБ  макс, МБ
-------------------------------------------------------------------------------------
MR baseline (1 worker, 1 MB)              9.80 ± 0.24               566.7     590.7
MR optimized (4 workers, 8 MB)            9.04 ± 0.66               864.5     916.3
MR 4 workers, 32 MB                       8.13 ± 0.11              1265.9    1367.2
MR v2 (4 workers, 8 MB)                   3.50 ± 0.05               952.8     954.2
DuckDB naive                             12.57 ± 0.39              1784.5    1910.4
DuckDB opt                                5.23 ± 0.07              1838.9    1898.5
```

Рис. 8. Профилирование: 6 вариантов × 3 запуска

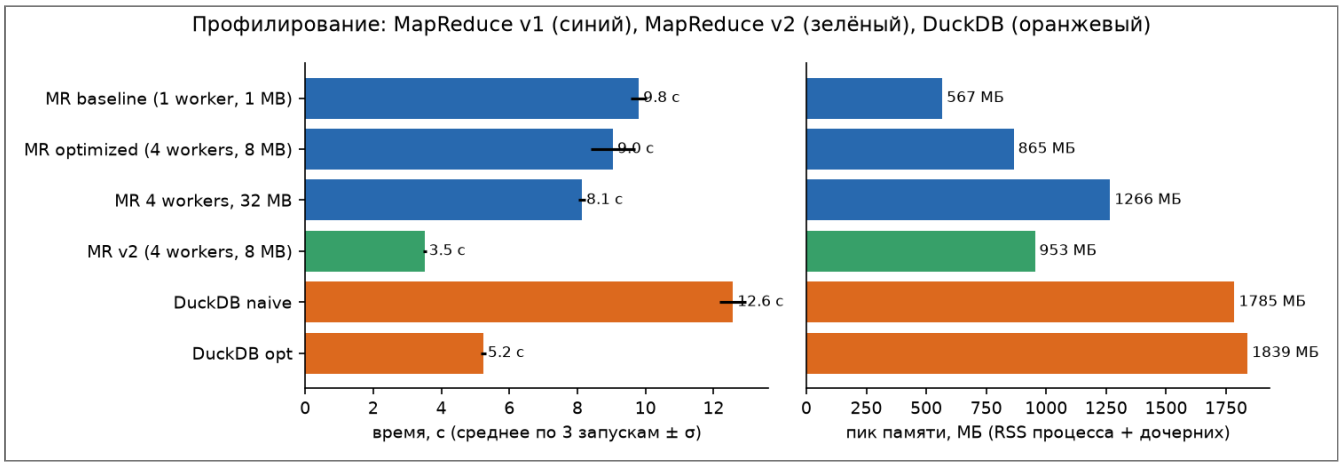


Рис. 9. Время и пик памяти

Сравнение «до → после»	**До**	**После**	**Эффект**
MapReduce: v1 (1 воркер, 1 МБ) → v2	9,80 с / 567 МБ	3,50 с / 953 МБ	**в 2,8 раза быстрее**, памяти ×1,7
MapReduce v1: 4 воркера, 8 МБ → 32 МБ	9,04 с / 865 МБ	8,13 с / 1 266 МБ	−10 % времени, +46 % памяти
DuckDB: naive → opt	12,57 с / 1 785 МБ	5,23 с / 1 839 МБ	**в 2,4 раза быстрее**, память та же
DuckDB opt → MapReduce v2	5,23 с / 1 839 МБ	3,50 с / 953 МБ	в 1,5 раза быстрее, вдвое меньше памяти

Объяснение.

- **MapReduce v1 почти не ускоряется от 4 воркеров (−8 %):** я замерила фазы отдельно — параллельна только фаза map (~1,2 с), а чтение объекта (~3 с) и shuffle 2,7 млн ключей (~3 с) выполняет один главный процесс. По закону Амдала эта последовательная часть и ограничивает ускорение. В v2 эти шаги перенесены в мапперы и редьюсеры, поэтому v2 в 2,6 раза быстрее v1 на тех же 4 воркерах.

- **Память MapReduce** растёт с числом процессов и размером чанка: каждый воркер — отдельный интерпретатор со своим чанком и своими счётчиками троек. Однопроцессный вариант самый экономный (567 МБ), чанк 32 МБ — самый «тяжёлый».
- **DuckDB naive → opt:** в наивном режиме каждый запрос заново скачивает 284 МБ из S3 и парсит CSV со всеми колонками; в оптимизированном CSV читается один раз и в памяти остаются только id и навыки. Пик памяти почти не меняется — его определяет самая большая таблица (1,1 млн троек) и хеш-агрегация self-join.
- **MapReduce v2 быстрее DuckDB**, потому что сочетания генерируются напрямую `combinations()` из списка навыков вакансии, а DuckDB строит тройки универсальным self-join. Зато решение на DuckDB — это несколько SQL-запросов без ручной работы с чанками, процессами и отказами.

8. Выводы

- RustFS поднят в Docker (EC:2, 4 диска); вакансии сегмента загружены в бакет `hh-lake`; найдена и обойдена особенность стенда — одиночный PutObject объектов больше ~256 КБ падает, multipart работает.
- Собственный MapReduce читает объект из S3 Range-запросами по чанкам с корректным разрезом многострочного CSV, использует combiner, shuffle по crc32 и редьюсеры, переживает отказ маппера. Результаты для k = 1, 2, 3 лежат в хранилище.
- DuckDB с самостоятельно написанным условием варианта дал **полностью совпадающие** результаты: 54 607 вакансий, 9 219 навыков, 157 717 пар, 1 116 083 тройки. Рост числа сочетаний объяснён и проверен точно: Σ C(n,2) и Σ C(n,3) совпали с числом вхождений.
- Зарплату повышают интеграционные и инженерные навыки (REST/SOAP/XML/JSON, Kafka, ERP на 1C, DWH, A/B-тесты), понижают — общие и офисные (Пользователь ПК, MS Excel, CRM, деловая переписка, «аналитическое мышление»). Важная находка — вакансии-клоны (29 % выборки), без их учёта выводы о «понижающих» навыках были бы ложными.
- Москва — половина рынка и самые высокие зарплаты (150 тыс. ₽ против 110 и 80); разрыв растёт с опытом и во многом объясняется более технологичным составом московских вакансий.
- Профилирование (6 вариантов × 3 запуска, время и пик памяти): DuckDB оптимизирован в 2,4 раза (одно чтение S3 вместо нескольких). Простое распараллеливание MapReduce дало лишь −17 % из-за последовательного драйвера и shuffle; после переноса чтения и shuffle в мапперы, spill на диск и параллельных редьюсеров (v2) MapReduce стал **в 2,8 раза быстрее** исходного (9,80 → 3,50 с) и обогнал DuckDB (5,23 с) при вдвое меньшей памяти.

Исходный код всех программ, логи запусков и результаты опубликованы в репозитории GitHub: `https://github.com/masha363/data-engineering-hw3`